Eliminación de artefactos en imágenes de endoscopía

Avance 2. Resultados de la prueba 1

Equipo

Mario Raúl García Ramírez - A01658682

Javier Emmanuel García Escobedo - A01411206

Juan Miguel Molina Reyes - A01796655

Profesor: Dr.Gilberto Ochoa Ruiz, EIC Computación

Patrocinador: Dr. Gerardo Jesús Camacho González, INSiDE Lab

Proyecto Integrador

11 de Octubre del 2026

Índice

1. Prueba 1: Pipeline completo sobre C3VDv2 **3**
1.1. Objetivo e hipótesis 3
1.2. Configuración experimental 3
1.3. Pasos del Pipeline 3

2. Resultados **4**
2.1. Error de profundidad por región 4
2.2. Significancia por frame 4
2.3. Otras métricas 5
2.4. Curvas de validación 5

3. Interpretación **5**

4. Limitaciones y validez de los resultados **5**
4.1. Fuga de información entre entrenamiento y prueba 5
4.2. Otras limitaciones 6

5. Siguientes pasos **6**

6. Archivos y reproducibilidad **6**

Bibliografía **6**

1. Prueba 1: Pipeline completo sobre C3VDv2

1.1. Objetivo e hipótesis

La Prueba 1 es la primera corrida completa del pipeline del proyecto con datos reales: Endo-STTN [3] limpia los reflejos especulares de los frames, un estimador de profundidad se ajusta con la profundidad real del conjunto de datos y se evalúa contra esa misma referencia. Su propósito es doble: (1) comprobar que el pipeline funciona de extremo a extremo con una muestra pequeña del conjunto C3VDv2 [1, 2], y (2) obtener una primera estimación del efecto de limpiar los reflejos sobre la estimación de profundidad.

La hipótesis es que un estimador de profundidad entrenado y evaluado con frames limpiados comete menos error que uno entrenado y evaluado con frames originales, sobre todo dentro y alrededor de los reflejos.

1.2. Configuración experimental

Datos y partición. La Tabla 1 resume la configuración. Se usaron cinco videos de C3VDv2 (tres de entrenamiento, uno de validación y uno de prueba). Cada video se submuestreó a 1 de cada 5 frames (hasta 300 por video) y se redimensionó a 320×256. La profundidad real, almacenada como TIFF de 16 bits, se convirtió a milímetros (0–100 mm; los valores 0 y 65535 se tratan como "sin dato"). La máscara de reflejos marca los píxeles con brillo (escala de grises) mayor o igual a 230, dilatados 3 px a 320×256. La partición se hace por video (nunca por frame): el código fija listas de videos de prueba y de validación y asigna a entrenamiento todos los demás videos disponibles.

Tabla 1: Configuración de la Prueba 1.

Fecha / entorno	11 oct. 2026; Google Colab, GPU Tesla T4
Entrenamiento	`c2_descending_t4_v1`, `c2_descending_t4_v2`, `c2_rectum_t1_v1`
Validación	`c2_descending_t3_v1` (elige la mejor época)
Prueba	`c2_descending_t4_v3` (26 frames)
Limpieza	Endo-STTN preentrenado (`gen_00009.pth`), sin entrenar; solo modifica píxeles de reflejo
Estimador	AF-SfMLearner [4], pesos *End-to-end* preentrenados en SCARED [5]
Ajuste fino	Pérdida *scale-invariant log*; Adam, lr 10^{-4} (decoder) y 10^{-5} (encoder); lote 8; 15 épocas; semilla 0

Variantes comparadas. Se evalúan cuatro modelos que combinan el estimador (con pesos de SCARED o ajustado en C3VDv2) con el tipo de frame de entrada (originales o limpiados):

Tabla 2: Variantes de modelo evaluadas.

	Pesos	Entrada	Ajuste fino con
A	SCARED	originales	—
B	SCARED	limpios	—
C	ajustado	originales	originales
D	ajustado	limpios	limpios

1.3. Pasos del Pipeline

1. **Preparación de datos.** Submuestreo, redimensionado, conversión de profundidad y cálculo de máscaras (Figura 1).
2. **Limpieza.** Endo-STTN sustituye los píxeles de reflejo. La verificación del notebook confirma que **0 píxeles cambiaron fuera de la máscara**, es decir, la limpieza no altera el resto de la imagen (Figura 2).
3. **Ajuste fino.** Se entrenan C (frames originales) y D (frames limpios) con la profundidad real; se conserva la época con menor AbsRel de validación.
4. **Evaluación.** Se evalúan A, B, C y D sobre los 26 frames de prueba con escalamiento por mediana (*median scaling*) usando toda la imagen. Las métricas son AbsRel, Sq-Rel, RMSE (mm), RMSE log y $\delta < 1{,}25$, calculadas en tres regiones: toda la imagen, dentro de los reflejos y un anillo de

10 px alrededor de ellos. Las diferencias entre modelos se contrastan con la prueba de Wilcoxon pareada por frame.

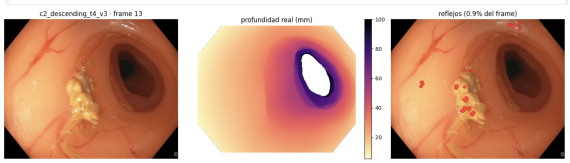


Figura 1: Frame 13 del video de prueba: imagen, profundidad real (mm; en blanco, sin dato) y máscara de reflejos (0.9 % del frame).

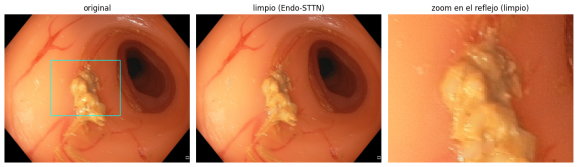


Figura 2: Frame original, frame limpiado por Endo-STTN y detalle ampliado.

2. Resultados

2.1. Error de profundidad por región

La Tabla 3 y la Figura 3 muestran el AbsRel en el video de prueba.

Tabla 3: AbsRel en el video de prueba (menor es mejor).

Modelo	Imagen	Reflejos	Anillo
A (SCARED, orig.)	0.404	0.753	0.476
B (SCARED, limpios)	0.399	0.744	0.457
C (ajustado, orig.)	0.089	0.111	0.104
D (ajustado, limpios)	**0.078**	**0.085**	**0.075**
Cambio C → D	−12,4 %	−23,0 %	−27,8 %

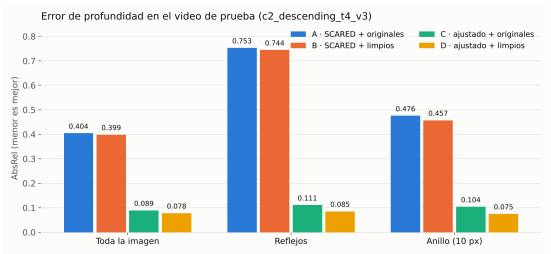


Figura 3: AbsRel por región y modelo.

El ajuste fino reduce el AbsRel en toda la imagen de 0.404 (A) a 0.089 (C), una caída de 78 %. Limpiar los frames sin reentrenar (A → B) mejora entre 1 y 4 % según la región. Entrenar y evaluar con frames limpios (C → D) mejora más en las regiones de interés (reflejos y anillo) que en la imagen completa. La Figura 4 muestra las predicciones y los mapas de error de los cuatro modelos en un frame de prueba.

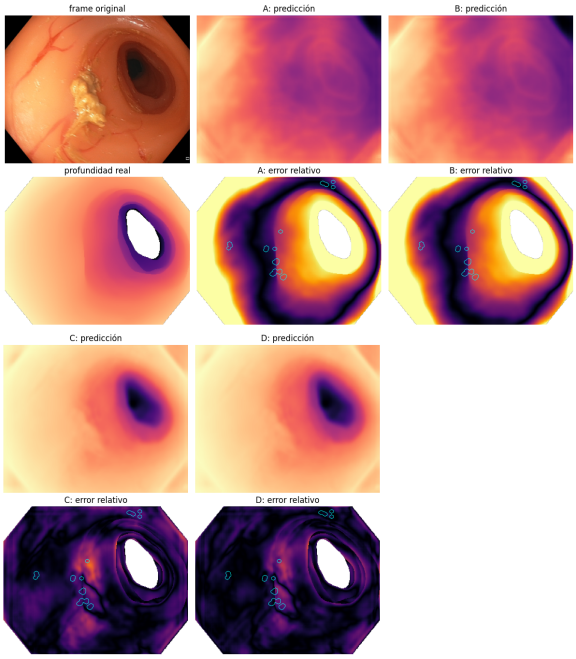


Figura 4: Profundidad predicha (arriba de cada bloque) y error relativo (abajo) de A–D en un frame de prueba; contornos: reflejos.

2.2. Significancia por frame

Se aplicó la prueba de Wilcoxon pareada sobre el AbsRel de los 26 frames (hipótesis alterna: el segundo modelo tiene menor AbsRel).

Tabla 4: Pruebas de Wilcoxon pareadas ($n = 26$ frames).

Comparación	Región	Mediana dif.	p
C vs D	reflejos	0.028	0.015
C vs D	imagen	0.018	0.0005
A vs B	reflejos	0.002	0.134

Las dos diferencias C vs D resultan significativas al nivel 0.05 y siguen por debajo del umbral de Bonferroni para tres pruebas ($0{,}05/3 \approx 0{,}017$), aunque la de reflejos lo hace por poco. La diferencia A vs B no es significativa. Estos valores de p deben leerse con

cautela (véase la Sección 4).

2.3. Otras métricas

Tabla 5: Métricas por región para los modelos ajustados (en negritas, el mejor).

Región	Mod.	AbsRel	SqRel	RMSE	RMSE log	δ_1
Imagen	C	0.089	0.334	**3.67**	0.112	0.950
	D	**0.078**	**0.321**	3.82	**0.102**	**0.958**
Reflejos	C	0.111	0.242	1.95	0.130	**0.929**
	D	**0.085**	**0.202**	**1.71**	**0.110**	0.910
Anillo	C	0.104	0.243	2.04	0.125	0.925
	D	**0.075**	**0.176**	**1.72**	**0.101**	**0.931**

RMSE en mm; δ_1 denota $\delta < 1{,}25$. Las tablas completas de A–D están en el archivo `evaluacion_resumen.md` del repositorio.

2.4. Curvas de validación

En validación, C y D terminan prácticamente iguales (mejor AbsRel de 0.156 y 0.154, respectivamente); D desciende más rápido entre las épocas 3 y 7 (Figura 5). El AbsRel de validación (cercano a 0.155) es casi el doble del obtenido en prueba (0.078–0.089), diferencia que se discute en la Sección 4.1.

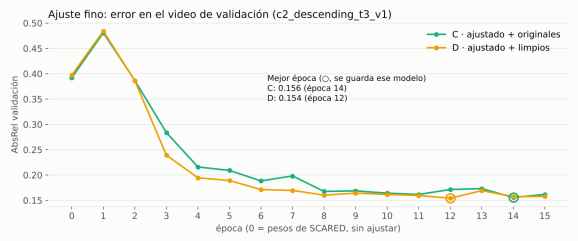


Figura 5: AbsRel de validación por época para C y D.

3. Interpretación

1. **El ajuste fino pesa más que la limpieza.** AF-SfMLearner, entrenado en SCARED (tejido porcino), no se transfiere bien a los modelos de silicona de C3VDv2 sin adaptación (A → C: −78 % de AbsRel).
2. **Limpiar ayuda cuando el estimador aprende con frames limpios.** D mejora a C en casi todas las métricas, y más en reflejos y anillo, lo cual es coherente con la hipótesis.
3. **Limpiar sin reentrenar aporta poco.** B frente a A mejora solo 1–4 % y no es significativo ($p = 0{,}134$); el beneficio parece requerir que el estimador se entrene con el mismo tipo de imagen que recibe.
4. **No todas las métricas favorecen a D.** El RMSE en toda la imagen (3.82 frente a 3.67 mm) y $\delta < 1{,}25$ en reflejos (0.910 frente a 0.929) son ligeramente peores. D reduce el error relativo, pero no gana en todos los criterios.

4. Limitaciones y validez de los resultados

4.1. Fuga de información entre entrenamiento y prueba

La estrategia de muestreo del equipo establece que la partición debe hacerse por segmento del fantoma para evitar fuga de información (Estrategia de muestreo, §1.4). En la Prueba 1 esa regla no se cumplió. La causa está en el código: `codigo/c3vd.py` reparte por video, con listas fijas de videos de prueba y de validación, y manda a entrenamiento todos los demás; no agrupa por segmento. Así, el video de prueba `c2_descending_t4_v3` quedó junto con `t4_v1` y `t4_v2`, del mismo segmento (`c2_descending_t4`), en entrenamiento. Lo mismo ocurriría con cualquiera de los otros videos de prueba predefinidos si se descargan sus v1 o v2.

Los videos de un mismo segmento comparten fantoma y trayectoria. No se verificó cuánto se parecen sus mapas de profundidad, pero es esperable que sean muy similares. Dos indicios apuntan a que los valores absolutos son optimistas: el AbsRel de validación, en un video de otro segmento (`c2_descending_t3_v1`), es cercano a 0.155, casi el doble del de prueba; y el propio README reconoce que prueba y entrenamiento comparten textura. Por eso, **las cifras absolutas (p. ej., AbsRel 0.089) no deben interpretarse como el desempeño esperado en un segmento nuevo**, ni la magnitud de la mejora A → C co-

mo una medida de generalización. La comparación C vs D sigue siendo controlada, porque la misma partición afecta a ambos modelos por igual; sin embargo, no se puede descartar que parte de la ventaja de D dependa de esa cercanía entre entrenamiento y prueba.

4.2. Otras limitaciones

Tamaño de muestra y pruebas estadísticas. Hay un solo video de prueba con 26 frames, y frames consecutivos están correlacionados, por lo que los valores de p (que suponen observaciones independientes) son optimistas. Además, se hicieron tres pruebas sin corrección formal más allá de la comparación con el umbral de Bonferroni indicada arriba.

Una sola semilla. No se conoce todavía cuánto varía la diferencia C–D con otra inicialización del entrenamiento.

Pocos datos de entrenamiento. Solo se usaron tres videos de entrenamiento, de una misma región del colon y del recto.

Máscaras y métricas. Las máscaras se obtienen por umbral de brillo (230) con dilatación de 3 px, por lo que pueden incluir también otros objetos brillantes distintos de los reflejos (p. ej., residuos o moco), y se evalúan solo sobre los píxeles con profundidad válida. Además, la mejora no es uniforme en todas las métricas (Sección 3).

Entorno. La prueba se ejecutó en Colab (Tesla T4), con un entorno distinto al de los autores de Endo-STTN; los valores de referencia del artículo original no son directamente comparables con los de esta prueba.

5. Siguientes pasos

Los siguientes puntos son propuestas para la Prueba 2 y quedan por acordar con el equipo:

1. **Criterio de partición.** Revisar el criterio de partición frente a la Estrategia de muestreo (§1.4), de modo que los videos de prueba no compartan segmento con los de entrenamiento. En particular, `c2_rectum_t1_v3`, citado en el README como textura no vista, comparte segmento con `c2_rectum_t1_v1`, usado para entrenar.
2. **Más semillas.** Repetir C y D con las semillas 1 y 2 y reportar media ± desviación estándar.
3. **Más videos de prueba y de entrenamiento**, incluyendo otras secciones del colon (p. ej., `c1_ascending_*`).
4. **Análisis estadístico.** Aplicar una corrección por comparaciones múltiples y, de ser posible, agregar los resultados por video en lugar de por frame.

6. Archivos y reproducibilidad

- `Equipo19_Avance2_colab_ejecutado.ipynb`: notebook de Colab con todas las celdas ejecutadas.
- `evaluacion_resumen.md`: tablas completas A–D y pruebas de Wilcoxon (hay una versión `.csv` con las medias).
- `evaluacion_por_frame.csv`: métricas de cada uno de los 26 frames.
- `historial_C_rgb.json` y `historial_D_rgb_limpio.json`: AbsRel de validación por época y configuración de cada ajuste fino.

Bibliografía

[1] Golhar, M. V., Galeano Fretes, L. S., Ayers, L., Akshintala, V. S., Bobrow, T. L., & Durr, N. J. (2025). C3VDv2 – Colonoscopy 3D video dataset with enhanced realism. *arXiv preprint* arXiv:2506.24074.

[2] Durr Lab @ JHU: Computational Biophotonics. Data associated with

the publication: C3VDv2: 3D colonoscopy video dataset with enhanced realism [Conjunto de datos]. Johns Hopkins Research Data Repository. https://doi.org/10.7281/T1/JC64MK

[3] Daher, R., Vasconcelos, F., & Stoyanov, D. (2023). A temporal learning approach to inpainting endoscopic specularities and its effect on image correspondence. *Medical Image Analysis, 90*, 102994. https://doi.org/10.1016/j.media.2023.102994

[4] Shao, S., Pei, Z., Chen, W., Zhu, W., Wu, X., Sun, D., & Zhang, B. (2022). Self-supervised monocular depth and ego-motion estimation in endoscopy: Appearance flow to the rescue. *Medical Image Analysis, 77*, 102338. https://doi.org/10.1016/j.media.2021.102338

[5] Allan, M., Mcleod, J., Wang, C., et al. (2021). Stereo correspondence and reconstruction of endoscopic data challenge. *arXiv preprint* arXiv:2101.01133.