# Eliminación de reflejos especulares en video de colonoscopía y su efecto en la estimación de profundidad: actualización de proyecto

Javier Emmanuel García Escobedo, Mario Raúl García Ramírez, Juan Miguel Molina Reyes

*Equipo 19, Proyecto Integrador · 22 de octubre de 2026*

**Resumen.** Esta actualización describe el estado del proyecto al cierre del tercer avance. El objetivo es evaluar si la eliminación de reflejos especulares mediante *inpainting* temporal (Endo-STTN) mejora la estimación monocular de profundidad (AF-SfMLearner) en el conjunto de datos C3VDv2. En el segundo avance, el ajuste del estimador a C3VDv2 redujo el error relativo de 0.404 a 0.089, y el uso de frames limpios redujo adicionalmente el error dentro de los reflejos en 23 % ($p = 0.015$), aunque con una evaluación limitada a un solo video. En el tercer avance se preparó el re-entrenamiento de Endo-STTN con datos de C3VDv2. Al analizar las máscaras de reflejos necesarias para ese entrenamiento se encontró que el método de detección original marca en promedio 4 % de la imagen y hasta 27 % en algunos frames, principalmente zonas de tejido pálido sobreexpuesto. El re-entrenamiento con dos métodos de máscara se encuentra en curso.

## 1. Introducción

En las imágenes de colonoscopía, la iluminación coaxial del endoscopio y la superficie húmeda de la mucosa producen reflejos especulares: regiones pequeñas, saturadas y de color cercano al blanco, cuya posición cambia con el movimiento de la cámara. Estos reflejos ocultan la textura del tejido y afectan a los métodos de estimación de profundidad a partir de una sola imagen, que interpretan las variaciones de intensidad como información de forma.

El proyecto estudia si eliminar los reflejos antes de estimar la profundidad reduce el error de estimación. Para la eliminación se utiliza Endo-STTN [1], un modelo de *inpainting* de video que rellena las regiones ocultas con información de frames vecinos. Para la profundidad se utiliza AF-SfMLearner [2]. Los experimentos se realizan con C3VDv2 [3], un conjunto de videos de colonoscopía adquiridos en modelos de colon de silicona que incluye la profundidad real de cada frame.

## 2. Datos

C3VDv2 contiene 192 videos adquiridos sobre 60 segmentos de dos fantomas de colon. Los 169 videos registrados incluyen, para cada frame, profundidad (0 a 100 mm), normales de superficie, flujo óptico, una imagen difusa renderizada y la pose de la cámara. Cada segmento puede tener tres versiones: v1 (colon limpio, trayectoria de referencia), v2 (colon limpio, otra trayectoria) y v3 (misma trayectoria que v2, con residuos).

En el primer avance se analizó una muestra de cinco videos (860 frames). No se encontraron archivos dañados. Los reflejos especulares ocuparon alrededor del 1 % de la imagen y los frames consecutivos resultaron muy similares entre sí (índice SSIM superior a 0.8 hasta una separación de 4 a 8 frames), por lo que en los experimentos de profundidad se utilizó uno de cada cinco frames.

## 3. Experimento inicial: limpieza y estimación de profundidad

En el segundo avance se comparó el error de profundidad de cuatro configuraciones del estimador: con sus pesos originales (entrenados en el conjunto SCARED) o ajustado con C3VDv2, y usando frames originales o frames limpiados con Endo-STTN en su versión publicada. El ajuste utilizó una pérdida logarítmica invariante a escala y se evaluó con el error relativo absoluto (AbsRel) en un video no utilizado para entrenar, tanto en la imagen completa como dentro de los reflejos y en un anillo de 10 px alrededor de ellos.

**Tabla 1.** Error relativo absoluto (AbsRel) en el video de prueba c2_descending_t4_v3.

| Configuración | Imagen completa | Reflejos | Anillo |
|---|---|---|---|
| A. Pesos originales, frames originales | 0.404 | 0.753 | 0.476 |
| B. Pesos originales, frames limpios | 0.399 | 0.744 | 0.457 |
| C. Ajustado a C3VDv2, frames originales | 0.089 | 0.111 | 0.104 |
| D. Ajustado a C3VDv2, frames limpios | 0.078 | 0.085 | 0.075 |

El ajuste al dominio produjo la mayor reducción del error (78 % entre A y C). Entrenar y evaluar con frames limpios (D) redujo el error respecto a C en 12 % en la imagen completa, 23 % dentro de los reflejos y 28 % en el anillo. La diferencia en los reflejos fue significativa en una prueba de Wilcoxon pareada por frame ($p = 0.015$). Limpiar los frames sin re-entrenar el estimador no produjo cambios significativos (B frente a A, $p = 0.13$).

Este resultado se considera preliminar: la evaluación se realizó en un solo video de 26 frames, que además comparte segmento con dos de los videos de entrenamiento, y con una sola inicialización del modelo.

## 4. Re-entrenamiento de Endo-STTN

### *4.1 Planteamiento*

A partir de la retroalimentación de los asesores del proyecto se decidió atender primero la calidad del relleno. Endo-STTN fue entrenado por sus autores con colonoscopías humanas, cuyas características de color, textura y reflexión difieren de las de un fantoma de silicona. Por ello, antes de repetir la evaluación de profundidad, se re-entrena Endo-STTN con frames de C3VDv2 partiendo del modelo publicado. También se modificó la división de los datos para que todas las versiones de un mismo segmento queden en el mismo conjunto (entrenamiento, validación o prueba).

El entrenamiento de Endo-STTN no requiere imágenes sin reflejos. La máscara de reflejos de cada frame se desplaza 50 px sobre tejido sin reflejos y el modelo aprende a reconstruir esa región, cuyo contenido es conocido. Esta misma estrategia se utiliza para evaluar el relleno. Como consecuencia, el modelo depende de contar con una máscara de reflejos confiable para cada frame, que C3VDv2 no proporciona.

### *4.2 Detección de reflejos*

Se implementaron cuatro métodos de detección: un umbral de brillo, una regla en el espacio HSV (brillo alto y saturación baja), el método de El Meslouhi et al. [4], utilizado por los autores de Endo-STTN, y una versión simplificada del método de Arnold et al. [5], diseñado para endoscopía. Se intentó además construir una máscara de referencia a partir de la imagen difusa de C3VDv2, que no contiene componente especular. Esta referencia no resultó utilizable, ya que la imagen renderizada no coincide con la imagen real en los bordes de los pliegues y la referencia marcaba esos contornos en lugar de los reflejos. Por esta razón, los métodos se evaluaron mediante estadísticas de cobertura y revisión visual.

### *4.3 Resultados de la detección*

Sobre seis videos de distintas regiones del colon (40 frames por video), el método de El Meslouhi marcó en promedio 3.97 % de la imagen (mediana 1.32 %), un valor cercano a cuatro veces el estimado en el primer avance. La cobertura varió considerablemente entre videos (Tabla 2).

**Tabla 2.** Porcentaje de la imagen marcado por el método de El Meslouhi.

| Video | Región | Media | Mediana | Máximo |
|---|---|---|---|---|
| c2_rectum_t1_v1 | Recto | 11.33 | 12.47 | 23.31 |
| c2_cecum_t1_v1 | Ciego | 5.73 | 3.71 | 27.10 |
| c1_ascending_t3_v1 | Ascendente | 2.59 | 2.17 | 11.41 |
| c2_transverse1_t1_v1 | Transverso | 2.48 | 2.25 | 6.55 |
| c2_descending_t4_v2 | Descendente | 1.47 | 0.84 | 11.17 |
| c2_sigmoid_t3_v2 | Sigmoide | 0.21 | 0.05 | 1.33 |

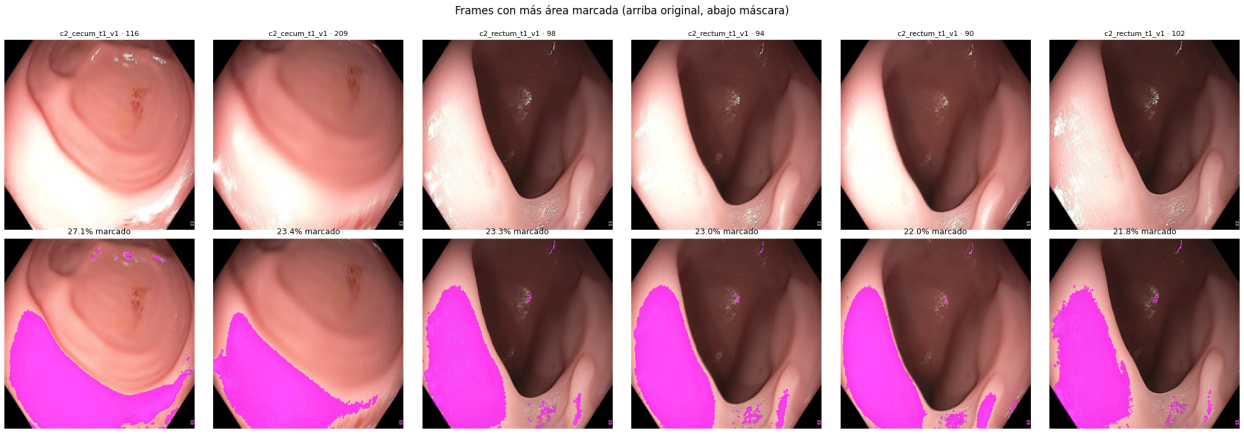



**Figura 1.** Frames con mayor área marcada por el método de El Meslouhi. Fila superior: imagen original. Fila inferior: máscara (magenta). Las regiones extensas corresponden a pared pálida sobreexpuesta cercana a la cámara.

La revisión visual mostró que, en los videos de recto y ciego, las regiones de mayor tamaño corresponden a mucosa pálida y sobreexpuesta, no a reflejos especulares (Figura 1). El criterio del método, que identifica

píxeles claros y de baja saturación, se cumple también en estas zonas. Si se entrena con estas máscaras, el modelo aprendería a rellenar tejido sano. El método de Arnold, más sensible, marcó en promedio 7.6 % de la imagen, y la regla HSV, más conservadora, 2.1 %.

### *4.4 Estado del entrenamiento*

El re-entrenamiento de Endo-STTN se encuentra en curso y se realiza en paralelo con dos máscaras para comparar su efecto sobre la calidad del relleno: Juan entrena con la máscara de Arnold y Mario con la de El Meslouhi. Ambos utilizan la misma división de datos (cuatro segmentos para entrenamiento, uno para validación y uno para prueba), 2,000 iteraciones y el modelo publicado como punto de partida. El mejor punto de control de cada entrenamiento se seleccionará con el video de validación, y los dos modelos se compararán contra el original en el video de prueba mediante PSNR, SSIM y error absoluto medio en la región desplazada. Al momento de esta actualización no se cuenta todavía con resultados.

De manera paralela, Javier se encarga de la revisión de información y de la recopilación de antecedentes (*information gathering*): revisa la literatura sobre detección de reflejos especulares e *inpainting* en endoscopía, así como la documentación de C3VDv2, para respaldar la elección de la máscara y orientar las siguientes etapas del proyecto.

## 5. Discusión y limitaciones

Los resultados del segundo avance sugieren que la eliminación de reflejos es útil cuando el estimador se entrena con imágenes procesadas de la misma manera, pero el tamaño de la evaluación no permite generalizar. El análisis del tercer avance indica además que la detección de reflejos, considerada inicialmente un paso resuelto, es una fuente importante de error en este conjunto de datos. Las principales limitaciones actuales son el número reducido de videos de evaluación, la falta de una referencia confiable para medir la calidad de las máscaras y el costo computacional del entrenamiento (aproximadamente 4.6 s por iteración en la GPU disponible).

## 6. Trabajo futuro

Una vez concluidos los entrenamientos, se seleccionará el modelo de Endo-STTN con mejor desempeño en el relleno. El cuarto avance utilizará ese modelo en dos etapas. En la primera, se limpiarán los frames y se ajustará el estimador de profundidad con ellos, usando la división por segmento, para confirmar o descartar la mejora observada en el segundo avance. En la segunda, se entrenarán Endo-STTN y el estimador de profundidad de manera conjunta (*end-to-end*), de forma que el error de profundidad también guíe el relleno de los reflejos. De manera paralela se evaluará el ajuste de la máscara elegida para excluir regiones extensas y sobreexpuestas.

## 7. Conclusiones

El ajuste del estimador de profundidad a C3VDv2 es indispensable, y la eliminación de reflejos muestra un beneficio preliminar dentro y alrededor de las regiones afectadas. Sin embargo, la calidad de ese beneficio depende de la definición de reflejo utilizada: en un colon de silicona, el método de detección original

confunde con frecuencia el tejido pálido sobreexpuesto con reflejos. Los entrenamientos en curso permitirán determinar el efecto de la máscara sobre el relleno de Endo-STTN, y el mejor modelo será la base para retomar la evaluación de profundidad.

## Referencias


[1] R. Daher, F. Vasconcelos y D. Stoyanov, "A temporal learning approach to inpainting endoscopic specularities and its effect on image correspondence," *Medical Image Analysis*, 2023.

[2] S. Shao *et al.*, "Self-supervised monocular depth and ego-motion estimation in endoscopy: Appearance flow to the rescue," *Medical Image Analysis*, 2022.

[3] M. V. Golhar *et al.*, "C3VDv2 – Colonoscopy 3D video dataset with enhanced realism," arXiv:2506.24074, 2025.

[4] A. El Meslouhi *et al.*, "Automatic detection and inpainting of specular reflections for colposcopic images," *Central European Journal of Computer Science*, 2011.

[5] M. Arnold, A. Ghosh, S. Ameling y G. Lacey, "Automatic segmentation and inpainting of specular highlights for endoscopic imaging," *EURASIP Journal on Image and Video Processing*, 2010.


El código, los notebooks y los resultados detallados se encuentran en el repositorio del equipo. En la elaboración del código y de este documento se utilizó un asistente de inteligencia artificial como apoyo; el contenido fue revisado por los integrantes del equipo.