PROYECTO INTEGRADOR · EQUIPO 19 · RESUMEN EJECUTIVO

Eliminación de reflejos especulares para mejorar la estimación de profundidad en colonoscopía

Estado del proyecto al cierre del Avance 3 (en curso)

Integrantes: Javier Emmanuel García Escobedo · Mario Raúl García Ramírez · Juan Miguel Molina Reyes · **Fecha:** 22 de octubre de 2026 · **Datos:** C3VDv2 (Johns Hopkins University)

Mensaje central. Quitar los reflejos especulares antes de estimar la profundidad muestra una mejora prometedora en nuestra primera prueba. Sin embargo, el resultado depende de un paso que habíamos dado por resuelto: **identificar con precisión dónde están los reflejos**. En un colon de silicona, el método de detección original confunde zonas de tejido pálido y sobreexpuesto con reflejos. Ese es hoy el cuello de botella del proyecto, y el re-entrenamiento de Endo-STTN que está en curso lo aborda directamente.

−78 %
error de profundidad al ajustar el estimador a C3VDv2 (Avance 2)

−23 %
error dentro de los reflejos al entrenar con frames limpios (p = 0.015, preliminar)

4 %
de la imagen marcado como reflejo por la máscara original, frente a ~1 % esperado (Avance 3)

27 %
máximo marcado en un frame: zonas sobreexpuestas, no reflejos

ESTADO ACTUAL: ENTRENAMIENTO EN CURSO

Endo-STTN se está re-entrenando con imágenes de C3VDv2 con dos máscaras de reflejos distintas, en paralelo, para comparar cuál produce un mejor relleno: **Juan Miguel Molina Reyes** entrena con la máscara de **Arnold et al. (2010)** y **Mario Raúl García Ramírez** con la máscara de **El Meslouhi et al. (2011)**, la que usaron los autores de Endo-STTN. Los resultados de ambos entrenamientos aún no están disponibles.

1 El problema

En colonoscopía, la luz del endoscopio rebota en la superficie húmeda del tejido y produce **reflejos especulares**: manchas blancas, muy brillantes, que ocultan el tejido y se mueven con la cámara. Los modelos que estiman profundidad a partir de una sola imagen interpretan ese brillo como si fuera forma, y fallan justo en esas zonas. La pregunta del proyecto es si **borrar los reflejos antes de estimar la profundidad** hace que la estimación se acerque más a la real.

Trabajamos con **C3VDv2**, un conjunto de videos de colonoscopía grabados en modelos de colon de silicona, que incluye la profundidad real de cada frame. Para borrar los reflejos usamos **Endo-STTN** (Daher et al., 2023), un modelo de *inpainting* temporal que rellena cada reflejo con lo que se ve en los frames vecinos; para la profundidad, **AF-SfMLearner** (Shao et al., 2022).

2 Conocer los datos (Avance 1)

La exploración de cinco videos (860 frames) confirmó que los datos están completos y sirvió para fijar decisiones de diseño posteriores:

- **Integridad:** sin archivos dañados; cada frame tiene su profundidad real (0–100 mm), normales y pose de cámara.
- **Reflejos:** ocupan alrededor del **1 %** de la imagen en los videos de referencia, pero están concentrados y saturados.
- **Redundancia:** los frames consecutivos son casi idénticos; a partir de 4–8 frames de distancia dejan de serlo. Por eso se toma 1 de cada 5.

3 Primera prueba: limpiar y medir (Avance 2)

Usamos Endo-STTN tal como lo publicaron sus autores para limpiar los frames y comparamos cuatro versiones del estimador de profundidad contra la profundidad real, en un video no usado para entrenar:

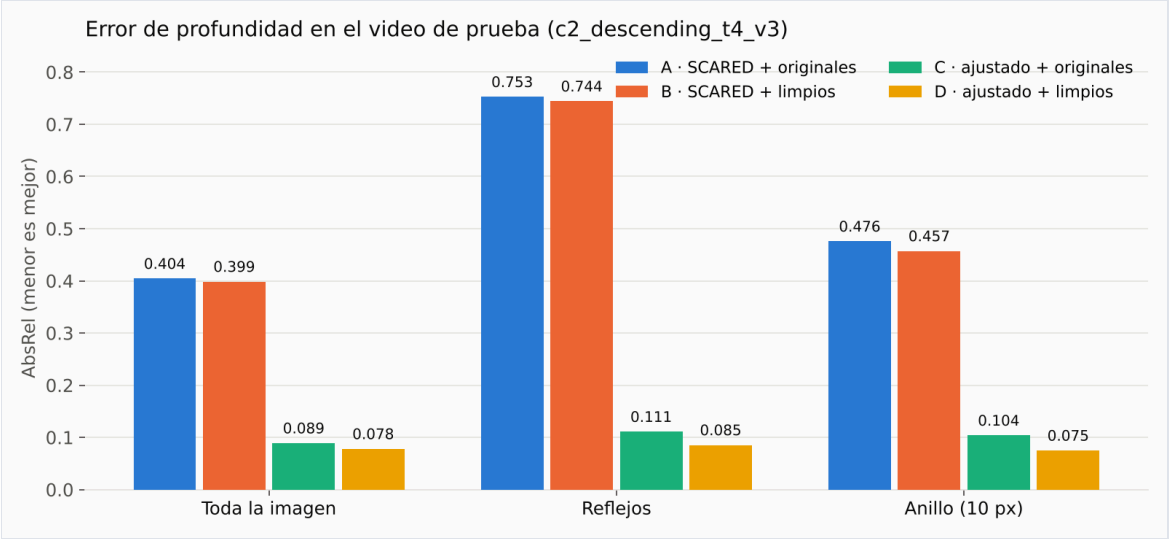


Figura 1. Error relativo (AbsRel, menor es mejor) en toda la imagen, dentro de los reflejos y en un anillo de 10 px alrededor. A y B: estimador original; C y D: ajustado con C3VDv2. B y D usan frames limpiados por Endo-STTN.

- **Ajustar el estimador al dominio es lo que más pesa:** el error baja 78 % (de 0.404 a 0.089).
- **Entrenar con frames limpios ayuda donde importa:** D tiene 23 % menos error que C dentro de los reflejos y 28 % menos alrededor (Wilcoxon por frame, p = 0.015).
- **Limpiar sin reentrenar no cambia nada** (B frente a A, p = 0.13).

Limitación: un solo video de prueba (26 frames) que comparte segmento del colon con dos videos de entrenamiento, y una sola semilla. El resultado es prometedor pero no concluyente.

4 Reorientación: primero el relleno, después la profundidad

A partir de la retroalimentación de los asesores del proyecto, se replanteó la prioridad. Endo-STTN fue entrenado por sus autores con colonoscopías humanas, no con modelos de silicona, que tienen otra textura, otro color y otros reflejos. Antes de volver a medir la profundidad, había que **re-entrenar Endo-STTN con imágenes de C3VDv2** y verificar que su relleno mejora en este dominio. Además, se corrigió la división de los datos para que ningún segmento del colon aparezca a la vez en entrenamiento y en prueba.

Para re-entrenar Endo-STTN se necesita una **máscara de reflejos por frame**, que C3VDv2 no incluye. El modelo aprende tapando una copia desplazada de esa máscara sobre tejido sano, cuyo color sí se conoce, y reconstruyéndola (*pseudo ground truth*). Por eso la calidad de la máscara determina directamente qué aprende el modelo.

5 Lo que encontramos al preparar el re-entrenamiento (Avance 3)

Se construyó el flujo completo: preparación de datos en el formato de Endo-STTN con división por segmento, cuatro métodos de detección de reflejos (umbral de brillo, regla HSV, El Meslouhi y Arnold), el entrenamiento original de Endo-STTN partiendo del modelo publicado y una evaluación con PSNR y SSIM. Al aplicar las máscaras a seis videos de distintas secciones del colon aparecieron tres hallazgos.

5.1 La máscara original marca más de lo que debería

El método de El Meslouhi (2011), el que usaron los autores de Endo-STTN, marca en promedio el **4 %** de la imagen (mediana 1.3 %), casi cuatro veces lo medido en el Avance 1. El comportamiento cambia mucho entre videos:

Video	Sección del colon	Marcado medio	Máximo por frame	Lectura
c2_rectum_t1_v1	**Recto**	**11.3 %**	**23.3 %**	**Marca la pared pálida sobreexpuesta**
c2_cecum_t1_v1	**Ciego**	**5.7 %**	**27.1 %**	**Marca zonas blanquecinas cercanas a la cámara**
c1_ascending_t3_v1	Ascendente	2.6 %	11.4 %	Reflejos y algunas zonas claras
c2_transverse1_t1_v1	Transverso	2.5 %	6.6 %	Mayormente reflejos
c2_descending_t4_v2	Descendente	1.5 %	11.2 %	Mayormente reflejos
c2_sigmoid_t3_v2	Sigmoide	0.2 %	1.3 %	Casi no marca

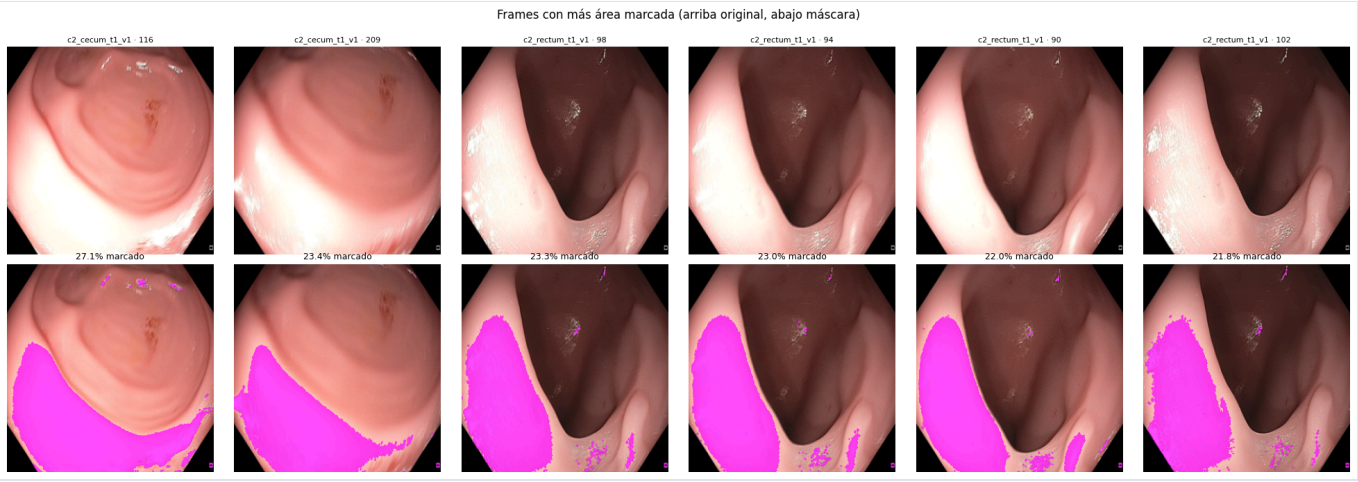


Figura 2. Los seis frames con más área marcada (arriba, original; abajo, máscara en magenta). Las zonas grandes corresponden a pared pálida sobreexpuesta cerca de la cámara, no a reflejos puntuales.

Si el modelo se entrena con estas máscaras, aprende a "borrar" tejido sano. El método fue diseñado para imágenes de tejido humano, cuyo color es más saturado; la mucosa pálida y muy iluminada de la silicona cumple

su criterio (claro y poco saturado) igual que un reflejo.

5.2 Los métodos alternativos no resuelven el problema por sí solos

El método de Arnold et al. (2010), diseñado para endoscopía, es el más sensible: detecta reflejos tenues que los demás pierden, pero marca aún más área (7.6 % en promedio). La regla HSV, que exige que el píxel sea brillante y casi sin color, es la más conservadora (2.1 %). Ningún método es claramente superior; por eso se re-entrena con dos de ellos en paralelo y se compararán por el resultado final.

5.3 El render 3D de C3VDv2 no sirve como referencia directa

Intentamos medir las máscaras contra una referencia física: C3VDv2 incluye un render del modelo 3D sin componente especular, y un píxel mucho más brillante que ese render debería ser un reflejo. En la práctica, el render no coincide con la imagen real en los bordes de los pliegues, y la referencia marcaba esos contornos en lugar de los reflejos. La comparación cuantitativa quedó descartada hasta corregir ese desalineamiento; la evaluación se apoya por ahora en estadísticas de cobertura y revisión visual de 50 frames por método.

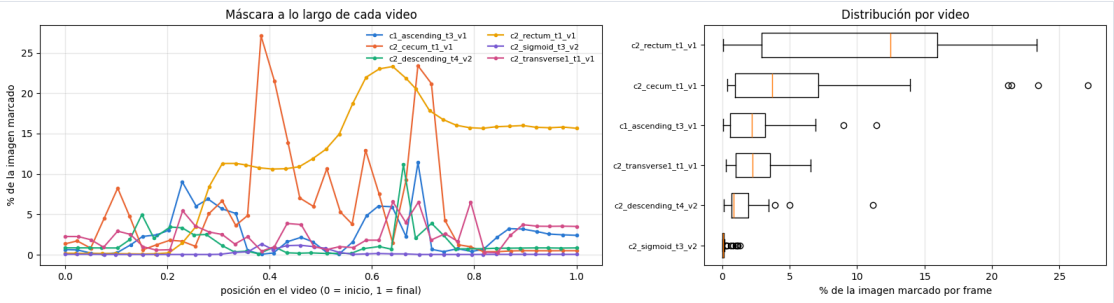


Figura 3. Porcentaje de la imagen marcado por la máscara de El Meslouhi a lo largo de cada video (izquierda) y su distribución por video (derecha). El recto y el ciego se separan claramente del resto.

6 Estado actual y siguientes pasos

Actividad	Responsable	Estado	Detalle
Exploración de datos (Avance 1)	Equipo	Completado	5 videos, 860 frames
Limpieza con Endo-STTN y ajuste del estimador (Avance 2)	Equipo	Completado	Resultado preliminar: −23 % de error en reflejos
Flujo de re-entrenamiento, métodos de máscara y evaluación	Equipo	Completado	Probado de punta a punta
Re-entrenamiento de Endo-STTN con máscara de Arnold	Juan Miguel Molina Reyes	En curso	2,000 iteraciones, checkpoints cada 500
Re-entrenamiento de Endo-STTN con máscara de El Meslouhi	Mario Raúl García Ramírez	En curso	Misma configuración, para comparar
Evaluación del relleno: original vs. re-entrenado (PSNR, SSIM)	Equipo	Pendiente	Al terminar los entrenamientos
Ajuste de la máscara (filtrar zonas grandes y sobreexpuestas)	Equipo	Pendiente	Según la comparación anterior

Selección del mejor Endo-STTN re-entrenado (*best performer*)	Equipo	Pendiente	Mayor PSNR y SSIM en videos de prueba

Siguiente avance · Avance 4: implementación end-to-end

Una vez que terminen los dos entrenamientos, el Endo-STTN re-entrenado con mejor desempeño en el relleno (*best performer*, Arnold o El Meslouhi) se usará para volver a la pregunta original del proyecto: si quitar los reflejos mejora la estimación de profundidad. El Avance 4 tendrá dos etapas:

- **Estimador entrenado con el mejor Endo-STTN.** Limpiar los frames con el *best performer* y ajustar AF-SfMLearner con ellos, con la división por segmento ya corregida. Se compara contra los modelos del Avance 2 para confirmar o descartar la mejora preliminar de −23 % en los reflejos, de preferencia con varias semillas.
- **Entrenamiento end-to-end.** Partiendo del *best performer*, entrenar Endo-STTN y el estimador de profundidad juntos, de modo que el error de profundidad también guíe cómo se rellenan los reflejos. El código ya está implementado y probado con datos sintéticos; queda en pausa hasta contar con el mejor Endo-STTN.

Lo que sabemos, lo que no y lo que sigue

Sabemos	Aún no sabemos	Siguiente paso
Ajustar el estimador de profundidad a C3VDv2 es indispensable.	Si la mejora del Avance 2 se mantiene sin compartir segmentos entre entrenamiento y prueba, y con más semillas.	Avance 4: entrenar el estimador con el mejor Endo-STTN y la división corregida.
Limpiar los frames sin re-entrenar el estimador no aporta.	Si re-entrenar Endo-STTN mejora su relleno en silicona.	Terminar los dos entrenamientos y comparar contra el modelo original.
La máscara original confunde tejido pálido sobreexpuesto con reflejos.	Qué máscara produce el mejor Endo-STTN.	Comparar Arnold y El Meslouhi por la calidad del relleno y ajustar la máscara elegida.

> **Conclusión.** Empezamos buscando mejorar la estimación de profundidad y encontramos que el reto principal está un paso antes: definir con precisión qué es un reflejo en un colon de silicona. Los resultados de los dos entrenamientos en curso indicarán qué tanto depende el relleno de Endo-STTN de esa definición, y el mejor de ellos será la base del Avance 4, donde se retoma la estimación de profundidad.

Referencias

R. Daher, F. Vasconcelos y D. Stoyanov, *A Temporal Learning Approach to Inpainting Endoscopic Specularities and Its Effect on Image Correspondence*, Medical Image Analysis, 2023. · S. Shao et al., *Self-Supervised Monocular Depth and Ego-Motion Estimation in Endoscopy: Appearance Flow to the Rescue*, Medical Image Analysis, 2022. · M. V. Golhar et al., *C3VDv2: Colonoscopy 3D Video Dataset with Enhanced Realism*, arXiv:2506.24074, 2025. · A. El Meslouhi et al., *Automatic detection and inpainting of specular reflections for colposcopic images*, Central European Journal of Computer Science, 2011. · M. Arnold, A. Ghosh, S. Ameling y G. Lacey, *Automatic segmentation and inpainting of specular highlights for endoscopic imaging*, EURASIP Journal on Image and Video Processing, 2010.

Código, notebooks y resultados en el repositorio del equipo (Avance1_ExploracionDatos, Avance2_DeepEstimator_EndoSTTN, Avance3_ReEntrenar_Endo). Elaborado con apoyo de Claude (Anthropic); revisado por el equipo.